gradiant

AVP3: Informe de resultados/ conclusiones

Alejandra Ares Rivas, Paula Esmorís Rodriguez, María Gómez Fernández

Resultados obtenidos

En cuanto a los resultados obtenidos se logró la creación de 769 imágenes realistas distribuidas en tres escenarios de mar, montaña y campo. Todas ellas etiquetadas correctamente de forma automática mediante scripts de Python que accediendo a los datos de Blender fueron capaces de generar el json en formato COCO con las etiquetas, incluyendo las características de cada imagen, así como bounding boxes precisas.

Para conseguir variabilidad se integraron variaciones críticas en el procesos de generación de imágenes que permiten testear los límites del modelo. A continuación se detallan las métricas tomadas en consideración:

1. **Variables de Entorno (Condiciones meteorológicas):** Estas métricas evalúan la capacidad de detección del modelo en diferentes condiciones meteorológicas, permitiendo comparar su eficiencia en paisajes despejados frente a condiciones de visibilidad más degradadas.
    a. **Densidad de niebla:** Se generaron imágenes con densidades de niebla variable, desde muy débiles hasta algunas donde la visibilidad era casi nula.
    b. **Lluvia:** Mediante sistemas de partículas de Blender se añadió lluvia, para ver cómo reacciona el modelo frente al ruido visual que generan las gotas.
    c. **Despejado:** Imágenes donde se ve claramente la aeronave en condiciones de sol, de esta forma nos sirve de línea base para ver cuánto empeoran las métricas frente a las condiciones previas.

2. **Diversidad de Escenarios (Contexto geoespacial):** Se generaron imágenes en diferentes escenarios paisajísticos para ver el impacto que puede tener en la detección que una aeronave aparezca en un espacio uniforme como un océano frente a otras donde el avión aparece frente a construcciones rocosas como una montaña o sobrevolando paisajes con objetos como árboles.
    a. **Mar:** Fondos uniformes con reflejos de luz en el agua pero sin obstáculos visuales.
    b. **Montaña:** Fondos más complejos y montañosos, con irregularidades en el terreno, rocas y vegetación. Lo que puede generar falsos negativos.
    c. **Campo:** Entornos naturales con árboles e incluso algún pequeño edificio.





3. **Métricas de configuración de la aeronave:** Están relacionadas con la posición del objeto detectado:
    a. **Distancias:** se aleatorizó la posición para poder capturar distancias cortas hasta muy largas, donde al avión apenas ocupa unos píxeles, pudiendo evaluar así la sensibilidad del modelo.
    b. **Movimiento por la escena:** Se varió la trayectoria de la aeronave, consiguiendo que esta aparezca en diferentes posiciones de la escena.
    c. **Rotación del avión:** Se probaron diferentes ángulos de vuelo para asegurar que el modelo es capaz de reconocer la silueta del modelo desde cualquier perspectiva (lateral, frontal, etc.). Para ello el avión se rota de forma aleatoria sobre su eje y también se añade cierta variabilidad en la inclinación, para simular trayectorias ascendentes o descendentes.
    d. **Variabilidad de la aeronave**: en los escenarios de mar y montaña se utilizó un helicóptero y en el de campo una avioneta.

4. **Parámetros adicionales:**
    a. **Luminosidad:** También se varió la luminosidad en la escena para poder simular mayor y menor intensidad del sol y así diferentes ambientes.

En cuanto a la validación realizada en el modelo YOLO, se han obtenido resultados con los datasets creados, que se compararon con los resultados de validación del mismo modelo con un dataset con imágenes reales. Antes de explicar las métricas obtenidas, cabe explicar que se obtuvieron dos tipos de métricas: **Precisión y Recall**.

Dentro de la precisión tenemos distintas métricas según la permisividad permitida al modelo:

- **IoU = 0.50**: es una métrica de detección general. Se considera que la IA ha acertado si la bounding box predicha tiene una intersección de al menos un 50% de coincidencia con la bounding box real.

- **IoU = 0.75**: esta métrica se centra más en la precisión de encuadre. Si la IA detecta una aeronave, pero dibuja un cuadro demasiado grande o movido, fallará.

- **IoU: 0.50:0.95**: es el promedio de las métricas ya que calcula la precisión en muchos niveles (de 0.50 hasta 0.95) y hace la media de todos.

Para el análisis de los resultados se seleccionará únicamente la **métrica IoU: 0.50:0.95**, al ser la que proporciona métricas más generales sobre los datasets.

En cuanto a la métrica del **Recall**, la cual mide la capacidad del modelo para encontrar todos los objetos reales presentes en las imágenes, se centra más en castigar los falsos negativos (no ver un objeto que sí está) en vez de los falsos positivos como la precisión (ver algo donde no hay nada).

A mayores, para cada una de estas métricas hay una específica para el **tamaño que ocupa el objeto en la imagen**, clasificando las imágenes entre **Small** (objetos lejanos), **Medium** (objetos a media distancia) y **Large** (objetos muy cerca de la cámara). El área **All** tiene en cuenta todas las distancias.

Métricas obtenidas:

Dataset	Nº imágenes	Precisión		Recall	
Airborne (real)	-	Area=small	0.46106	Area=small	0.54197
		Area=medium	0.68169	Area=medium	0.79293
		Area=large	0.78823	Area=large	0.79409
		Area=all	**0.48906**	**Area=all**	**0.57005**
Completo	769	Area=small	0.02253	Area=small	0.04790
		Area=medium	0.27748	Area=medium	0.36916
		Area=large	0.28780	Area=large	0.42697
		Area=all	**0.26915**	**Area=all**	**0.32800**
Campo/Avioneta	286	Area=small	0.04752	Area=small	0.04444
		Area=medium	0.42063	Area=medium	0.45352
		Area=large	0.60545	Area=large	0.62000
		Area=all	**0.38895**	**Area=all**	**0.41806**
Montaña	225	Area=small	-1.000*	Area=small	-1.000*
		Area=medium	0.20138	Area=medium	0.24750
		Area=large	0.06619	Area=large	0.08630
		Area=all	**0.10751**	**Area=all**	**0.14336**
Mar	258	Area=small	0.03087	Area=small	0.05135
		Area=medium	0.14386	Area=medium	0.31319
		Area=large	0.32431	Area=large	0.39847
		Area=all	**0.23605**	**Area=all**	**0.31892**
Niebla	273	Area=small	0.05982	Area=small	0.09762
		Area=medium	0.31391	Area=medium	0.38586
		Area=large	0.39612	Area=large	0.45000
		Area=all	**0.30759**	**Area=all**	**0.36353**

Lluvia	193	Area=small	0.00000	Area=small	0.00000
		Area=medium	0.14008	Area=medium	0.22243
		Area=large	0.17233	Area=large	0.19787
		Area=all	**0.14971**	**Area=all**	**0.18638**
Despejado	303	Area=small	0.02368	Area=small	0.04625
		Area=medium	0.35005	Area=medium	0.43320
		Area=large	0.18682	Area=large	0.22022
		Area=all	**0.33501**	**Area=all**	**0.39222**
Helicóptero	483	Area=small	0.02998	Area=small	0.05135
		Area=medium	0.14840	Area=medium	0.28246
		Area=large	0.19167	Area=large	0.23394
		Area=all	**0.17326**	**Area=all**	**0.23711**

Análisis métricas:

Atendiendo a los resultados obtenidos en las métricas, pueden extraerse varias conclusiones relevantes sobre el comportamiento del sistema en los distintos escenarios evaluados. En general, se observa que los resultados muestran un rendimiento diferente que varía en función de las condiciones del entorno y del tipo de imágenes analizadas.

Respecto a las áreas estudiadas, en la mayoría de los casos se alcanzan unas mejores métricas al trabajar con zonas donde el helicóptero tiene un mayor tamaño **(áreas más grandes)**. Esto se podría dar debido a que los objetos presentan un mayor número de píxeles dentro de la imagen, por lo tanto, tienen características visuales más definidas. Esta diferencia puede observarse sobre todo en los resultados del dataset correspondiente al escenario del campo, con una diferencia de recall entre áreas pequeñas y grandes de un **0,58.**

Por otro lado, al analizar los resultados del dataset completo se comprueba que estos son inferiores a los obtenidos en el dataset no sintético. Esta bajada se debe principalmente a dos factores: el escenario de **montaña** y la presencia de **lluvia**.

En el caso del entorno montañoso, las métricas obtenidas son las más bajas. Esto puede explicarse porque el fondo presenta una gran cantidad de elementos visuales complejos, como relieves, sombras, cambios de textura y variaciones de color, que dificultan la diferenciación entre el helicóptero y el entorno. Además, el helicóptero

puede quedarse camuflado con el paisaje, reduciendo su visibilidad y provocando un mayor número de errores en la detección. Esto tiene un impacto en los resultados del dataset de helicóptero, ya que aproximadamente la mitad de las imágenes de esa clase corresponden al escenario de montaña, lo que provoca que la precisión total del dataset de helicóptero también sea reducida.



Por último, se observa como la lluvia supone otro factor de disminución del rendimiento. La aparición de gotas en plano dificulta el análisis de los contornos y detalles del helicóptero. Como consecuencia, se tiene menos información visual útil para hacer una identificación correcta, aumentando la probabilidad de fallo y reduciendo las métricas finales.



Posibles desviaciones sobre el plan de proyecto inicial

El plan inicial del proyecto parte de resolver una deficiencia de los **sistemas Detect and Avoid (DAA) de Gradiant**, que consiste en la baja tasa de detección de aeronaves de ala fija. El plan definido al empezar era eliminar las barreras económicas y operativas que supone hacer unas imágenes con aeronaves reales creando un dataset sintético con la plataforma de generación 3D Blender. Por lo tanto, el objetivo principal era **generar un dataset de 500 imágenes de 3 escenarios diferentes y con variaciones** en parámetros como la distancia de la aeronave, la rotación o la iluminación de la escena. Una vez generado el dataset, la empresa proporcionaría su modelo YOLO-X usado para sus sistemas DAA y se realizaría una **validación del modelo** con el dataset generado.

Sin embargo, durante la realización del proyecto han surgido varias desviaciones:

- Surgió un **cambio en el organigrama inicial**, ya que de primeras, el equipo definió una metodología de trabajo basada en ciclos, y en cada ciclo se hacía una versión del dataset. Sin embargo, tras comprobar con el tutor que **las imágenes generadas en el primer ciclo eran válidas para el modelo**, se optó por reducir la estructura a un único ciclo de generación y centrar al equipo en hacer un dataset valioso y variado.





- Varias semanas después, el equipo ya tenía generados todos los escenarios y tenía también generadas varias imágenes con las variaciones propuestas inicialmente. Tras esto, el equipo docente trasladó la idea de **aumentar el alcance del proyecto** introduciendo más variabilidad en el dataset. Estas variaciones consistían en añadir condiciones climáticas, como lluvia o niebla a los escenarios para tener más variabilidad, así como tener una anotación en las imágenes en la que se indique el % de niebla que hay en cada imagen, con el objetivo de poder analizar posteriormente la capacidad del modelo YOLO de detectar las aeronaves en condiciones de alta densidad de niebla, por ejemplo.
- Tras las reuniones del equipo con el tutor de Gradiant, este último comentó la posibilidad de **aumentar la distancia de la aeronave en las imágenes**, para poner más a prueba al modelo, así como **generar imágenes en las que apareciese a los lados de las imágenes**, no siempre en el medio.





- El tutor también comentó la posibilidad de **evaluar las imágenes agrupadas de distintas formas en los datasets**, es decir, evaluar las imágenes con sus anotaciones **agrupadas por conceptos** (imágenes solo con lluvia, niebla, despejado, con solo el escenario de campo, montaña, mar o las imágenes que tuvieran solo helicóptero o avioneta). Con estas evaluaciones se puede obtener métricas de cada una de las situaciones por separado para poder ver así las fortalezas y debilidades del modelo.
- La idea inicial del proyecto era generar de cada escenario el mismo número de imágenes, pero por la **eficiencia operativa del renderizado**, para maximizar el

uso de los nodos de computación asignados se generó un **mayor volumen de imágenes en los escenarios más ágiles**, garantizando así una base de datos amplia en el menor tiempo posible. Escenarios como “Mar” o “Despejado” presentan una menor carga computacional y tiempos de renderizado más rápidos en comparación con escenarios más complejos como “Niebla” o “Montaña”.

Dificultades y problemas durante la ejecución

Durante el desarrollo se presentaron dos desafíos que afectaron al cronograma inicial y al proceso de validación:

1. **Sobrecarga en la Infraestructura de Computación (CESGA)**

Aunque se disponía de la infraestructura del CESGA para realizar el renderizado masivo de imágenes, la alta demanda del supercomputador y el sistema de gestión de colas provocaron retrasos en el lanzamiento de los scripts de generación. Para ello optamos por usar sesiones interactivas que nos permitieron ejecutar y depurar los scripts en tiempo real, corrigiendo fallos y añadiendo modificaciones , de esta forma se evitó la detención constante del flujo de trabajo.

2. **Compatibilidad y Ejecución del Modelo YOLO-X**

La validación del modelo proporcionado por la empresa presentó dificultades técnicas imprevistas. Surgieron problemas al intentar ejecutar los datasets tanto de forma local como en el cesga debido a dependencias de entorno y configuraciones específicas. Esto se resolvió mediante la colaboración directa del tutor de Gradiant, que ejecutó nuestros datasets y nos proporcionó las métricas de cada uno.

Acciones de mejora y evolución futura

Habiendo completado este proyecto se plantean una serie de acciones de mejora centradas sobre todo en los datos para aumentar su calidad, ya que es el núcleo principal del proyecto.

Una de las ventajas del enfoque adoptado es que permite que el sistema sea adaptable, lo que facilita la implementación de mejoras y permite reutilizar archivos generados en este proyecto base.

1. **Aumentar el dataset a formato de vídeo:**

Actualmente este proyecto únicamente se centra en la generación de un dataset a partir de imágenes. En un futuro se podría llegar a considerar la creación de secuencias de vídeo de manera sintética para validar el modelo. Esto permitiría simular escenarios mucho más realistas, donde la cámara se desplace, el objeto

cambie de posición progresivamente y las condiciones, como la iluminación o el enfoque, varíen.
Así se ayudaría a trabajar sobre tareas como el *tracking*, la predicción de trayectorias o la detección en tiempo real.

2. **Aumento en las condiciones meteorológicas y variación temporal:**

   En la versión actual se desarrollan varias condiciones atmosféricas, como lluvia o niebla, pero el sistema podría mejorar si se incorporan nuevas situaciones meteorológicas adversas o más complejas, como pueden ser las tormentas, la nieve, el humo, etc.
   Otra acción futura a tener en cuenta es la simulación de diferentes momentos del día y condiciones lumínicas, como escenarios nocturnos.
   La mejora también conlleva una combinación de dos o más de estas características, como lluvia y noche o niebla y amanecer.

3. **Ampliación de clase de objetos:**

   Actualmente el proyecto trabaja con dos tipos de aeronaves: una avioneta y un helicóptero. Sin embargo, el sistema podría escalar fácilmente a nuevas clases como aves, drones o cualquier obstáculo aéreo.
   Esto permitiría evolucionar a un sistema multicategoría más completo y realista.

4. **Mejora de anotaciones COCO:**

   Todas estas posibles evoluciones a futuro y ampliaciones de características supondrían un aumento de la cantidad de anotaciones en las etiquetas, por lo que habría que incorporar etiquetas más extensas, como la hora del día o la velocidad del objeto.

En cuanto a la evolución futura, el desarrollo de este dataset y los resultados favorables obtenidos podrían contribuir a la mejora del modelo. En lugar de utilizar estos datos únicamente para validación podrían emplearse también en fases de entrenamiento, permitiendo ajustar y perfeccionar el modelo proporcionado por la empresa para alcanzar una mayor rendimiento en distintos escenarios.

Además, al haber identificado puntos débiles del sistema, por ejemplo, en situaciones de larga distancia o condiciones de niebla, la empresa puede aprovechar esto para producir miles de imágenes específicas centradas en esos peores casos y reentrenar el modelo de forma dirigida, ayudando a una evolución constante de su rendimiento.

Conclusiones

La conclusión técnica fundamental del proyecto es que las imágenes sintéticas han funcionado como una buena herramienta de diagnóstico del modelo. Gracias a Blender se han conseguido recrear condiciones que en entornos reales serían muy costosas y peligrosas de capturar, por ejemplo, vuelos en condiciones de visibilidad muy limitada por la niebla o situaciones de mucha lluvia. Además, de esta forma se elimina el error humano en el etiquetado pues las bounding boxes se calculan automáticamente desde el motor 3D de Blender, garantizando que las métricas obtenidas realmente reflejan la capacidad del modelo. A mayores, el uso de datasets modulares permitió la identificación de la robustez del modelo en diferentes condiciones y escenarios, permitiendo generar un feedback para la empresa de posibles puntos a mejorar en el modelo YOLO-X.

Desde el punto de vista más estratégico, el proyecto demuestra una reducción en las barreras de entrada para la mejora de sistemas Detect and Avoid (DAA), pues la capacidad de generar un gran volumen de imágenes en tiempo reducidos supone un gran ahorro operativo frente a campañas de vuelos reales, que implican gastos de combustible, logísticos, permisos y cuentan con riesgos de seguridad. Es por ello que la conclusión principal del proyecto no ha sido la generación de imágenes, sino la capacidad de haber transformado un problema de falta de datos en una método de validación modular que permite a la empresa, Gradiant, saber cómo podría proceder a la hora de intentar mejorar su tasa de detección.